

파이널 프로젝트 계획 보고서

이 파일은 작성 예시를 보여주는 샘플입니다.

조 / 이름	3조 / 주영아, 이광호, 김OO, 박OO
제출일	2026-08-15
데이터셋 이름	국토교통부 아파트 매매 실거래가 자료
데이터 URL	https://www.data.go.kr/data/15058747/openapi.do

작성방법 설명

- 이 문서는 양식을 어느 정도 깊이로 채우면 되는지 보여주는 예시입니다. 그대로 베껴 내면 안 됩니다. 데이터가 다르면 채울 내용도 달라집니다.
- 각 절 맨 끝에는 **작성방법 설명** 인용문이 붙어 있습니다. 그 인용문은 작성 요령이고 나머지가 실제로 제출할 내용입니다. 인용문을 전부 지우면 그대로 제출본이 됩니다.
- 여러 데이터셋을 병합해서 사용하는 경우 표의 행을 늘려서 작성하세요.

1. 어떤 데이터인가

항목	설명
원본 출처	국토교통부가 신고받아 관리하는 아파트 매매 실거래 신고 자료를 공공데이터포털에서 공개한 원자료
수집 시점·기간	2024년 8월 ~ 2026년 7월 계약분 24개월치. 2026년 8월 12일 기준으로 내려받음
데이터 크기	59,842행 × 10열
파일 구성	자치구·계약월 단위로 나뉘어 있어 파일 600개를 하나로 합침. 열 구성이 모두 같아 그대로 이어 붙이면 됨
한 행의 데이터 단위	거래 1건. 아파트 단지가 아니라 계약 한 건이므로 같은 단지가 수십 번 들어간다

작성방법 설명

- 원본 출처** — 이 칸을 비워두지 마세요. 공공데이터라도 원래 어느 기관이 무슨 목적으로 만든 자료인지에 따라 값의 성격이 달라집니다.
 - 행정 절차에서 쌓인 자료인지, 조사나 설문으로 모은 자료인지, 누가 재가공해 올린 것인지 구분해 적습니다.
 - 남이 한 번 받아 재배포한 파일이라면 원래 어디서 나온 자료인지 거슬러 올라가 확인하세요. 중간에 값이 바뀌거나 일부만 잘려 있는 경우가 있습니다.
 - 설명 페이지에 synthetic, generated, simulated 같은 단어가 있으면 값을 만들어낸 자료입니다. 연습용으로 쓸 수는 있지만 “여기서 찾은 관계는 실제 세계의 관계가 아니다”라는 사실을 알고 시작해야 합니다.
- 수집 시점·기간**
 - 언제 찍은 자료인지 적습니다. 같은 출처라도 받는 날짜에 따라 내용이 달라지는 자료가 많습니다.

- 2020~2021년 데이터라면 코로나로 값이 크게 흔들렸을 수 있습니다. 그 시기를 빼고 해석하면 엉뚱한 결론이 나옵니다.
- 오래된 데이터를 쓰는 것 자체는 문제가 아닙니다. 다만 결론의 범위를 그 시점으로 한정해야 합니다.

• 데이터 크기

- 행 수를 먼저 봅니다. 학습·검증으로 나눈 뒤에도 판단할 만큼 남는지가 기준입니다.
- 집단을 나눠 비교할 계획이라면 가장 작은 집단에 몇 건이 남는지까지 확인하세요.
- 열이 지나치게 많으면 전처리에서 기간을 다 씁니다. 2절 후보 비교의 판단 근거가 되기도 합니다.

• 파일 구성

- 파일이 여러 개라면 무엇을 키로 붙일지, 붙인 뒤 남는 행이 몇 개인지까지 확인합니다.
- 조인 후 행이 절반으로 줄어드는 일이 자주 있습니다. 위 예시처럼 열 구성이 같아 그냥 이어 붙이면 되는 경우는 오히려 드뭅니다.

• 한 행의 데이터 단위

- 한 문장으로 못 쓰면 그 데이터는 아직 이해한 게 아닙니다.
- 사람 단위인 줄 알았는데 방문 1회 단위여서 같은 사람이 40번 들어가 있는 경우가 흔합니다. 이것 모르고 평균을 내면 자주 온 사람의 값이 40번 반영됩니다.
- 단위를 잘못 잡으면 이후 분석이 전부 어긋납니다. 여기서 확실히 정하고 넘어가세요.

• 표를 채우다 막히면

- 설명 페이지에 없어서 못 적는 칸은 “표기 없음”이라고 씁니다. 빈칸으로 두면 확인을 안 한 것인지 확인했는데 없는 것인지 구분이 안 됩니다.

2. 데이터 선정 이유

계기

수업에서 캘리포니아 주택 가격 데이터를 다루면서 재미있었는데 1990년 미국 이야기라 실감이 나지 않았다. 조원 중 둘이 자취방을 구하러 다니면서 같은 평수인데 구에 따라 가격이 몇 배씩 차이 나는 걸 보고 그 차이가 어디서 오는지 우리가 사는 도시의 데이터로 확인해 보고 싶어졌다. 면적 때문인지, 지은 지 얼마나 됐는지 때문인지, 아니면 그냥 어느 구인지가 전부인지 나눠서 보려 한다.

고른 이유

답하려는 질문에 필요한 값이 다 들어 있다. 실제로 오간 금액과 함께 전용면적·건축년도·층·계약일이 거래마다 붙어 있어서 자치구와 시점을 맞춰 놓고 나머지 조건을 비교할 수 있다. 계약일이 날짜 단위로 있는 점이 특히 중요했다. 후보 ②는 연도만 있어서 24개월 사이의 시장 흐름을 통제할 수 없었다. 서울만 24개월을 모아도 6만 건 규모라 구별로 쪼개 봐도 표본이 남는다.

비교한 다른 데이터셋 후보

후보 ①

데이터셋 이름	한국부동산원 청약홈 분양 정보
URL	https://www.applyhome.co.kr
크기	서울 기준 24개월간 약 90개 단지
제외한 이유	신규 분양가는 분양가상한제 같은 규제에 좌우된다. 단지 수도 90개뿐이라 구별로 나누면 한 자릿수만 남는다

후보 ②

데이터셋 이름	Korea Apartment Price (캐글)
URL	https://www.kaggle.com/datasets/gunhee/koreahousedata
크기	5,891행 × 30열
제외한 이유	2020년까지의 자료이고 대구 지역 위주다. 계약일 없이 연도만 있어 시점을 통제할 수 없다

후보 ③

데이터셋 이름	국토교통부 아파트 전월세 실거래가 자료
URL	https://www.data.go.kr/data/15058017/openapi.do
크기	서울 24개월 기준 약 21만 건
제외한 이유	보증금과 월세가 섞여 있어 하나의 Y로 묶기 어렵다. 전세와 월세를 같은 금액으로 볼 수 없어 질문부터 다시 짜야 한다

작성방법 설명

• 계기

- 왜 하필 이 주제가 궁금해졌는지를 2~3문장으로 씁니다. 개인적인 경험이나 수업에서 겪은 일에서 출발해도 됩니다.
- “취업에 도움이 될 것 같아서”, “데이터가 유명해서”는 계기가 아닙니다. 데이터로 답을 확인해 보고 싶은 궁금증이어야 합니다.
- 위 예시처럼 “어느 쪽 때문인지 나눠서 보고 싶다”는 식으로 쓰면 3절의 핵심 질문으로 자연스럽게 이어집니다.

• 고른 이유

- “데이터가 깨끗해서”, “결측치가 없어서”(×) — 판단 기준은 하나입니다. 답하려는 질문에 필요한 값이 실제로 들어 있는가.
- 시점을 통제해야 하는 질문이라면 날짜가 있는지, 집단을 비교할 질문이라면 집단 구분이 있는지 확인하세요.
- 행 수가 충분한지, 쓰려는 분석 방법에 표본이 남는지도 여기서 같이 밝힙니다.

• 비교한 다른 데이터셋 후보

- 최소 하나, 되도록 2~3개를 봅니다. 처음 검색해서 나온 걸 그대로 쓰면 대개 나중에 후회합니다.
- 비슷한 주제의 데이터를 몇 개 열어 보는 데는 30분이면 충분하고 그 30분이 5주를 아깁니다.
- 후보를 훑다 원래 쓰려던 데이터가 더 나아 보이기도 하고 반대로 후보 쪽으로 마음이 바뀌기도 합니다. 둘 다 정상이고 바뀌었다면 바뀐 이유를 적으면 됩니다.

• 제외한 이유 (후보 표)

- 취향이 아니라 데이터 쪽 사실로 적습니다.
- “재미없어서”(×) → “보증금과 월세가 섞여 있어 하나의 Y로 묶을 수 없음”(○)
- “어려워 보여서”(×) → “단지가 90개뿐이라 구별로 나누면 한 자릿수만 남음”(○)

3. 무엇을 분석할 것인가

- **한 문장 요약:** 전용면적·건축 연차·층·자치구로 서울 아파트의 매매 거래금액을 예측한다
- **핵심 질문:** 자치구와 계약 시점을 맞춰 비교했을 때도, 지은 지 오래된 아파트일수록 거래금액이 낮게 나타나는가?
- **문제 유형:** ☒ 회귀 ☐ 분류 ☐ 군집 ☐ 시계열
 - 근거: Y가 9,500~1,150,000만원 사이의 금액이라 연속형이다. “고가/저가”로 잘라 분류로 바꿀 수도 있지만 자르는 기준을 우리가 정해야 하고 “얼마나 차이 나는가”라는 정보가 버려진다.

목표변수 Y

컬럼명	거래금액
척도	연속형(비율척도), 단위 만원
분포 · 범주 비율	최소 9,500 / 중앙값 92,000 / 평균 128,340 / 최대 1,150,000. 평균이 중앙값보다 39% 크고 상위 1%가 20억을 넘음

설명변수 X

X ①

컬럼명	전용면적
의미 · 단위	아파트 전용면적, m ²
Y와 관련 있다고 보는 이유	Y와의 상관계수가 0.641로 숫자 컬럼 중 가장 크다. 넓을수록 비싸다는 건 당연하지만 다른 변수의 효과를 보려면 먼저 넣어 통제해야 하는 값이다

X ②

컬럼명	자치구 — 지역코드 5자리를 구 이름으로 변환
의미 · 단위	서울 25개 자치구 범주 (강남구 4,182 / 노원구 3,905 / ... / 종로구 612)
Y와 관련 있다고 보는 이유	구별 Y 중앙값이 강남구 245,000 vs 노원구 51,500으로 다섯 배 가까이 벌어진다. 입지가 가격의 대부분을 설명하므로 이걸 통제하지 않으면 나머지 변수는 아무것도 못 보여준다

X ③

컬럼명	층
의미 · 단위	거래된 물건의 층, 층
Y와 관련 있다고 보는 이유	1층은 기피하고 고층은 선호한다는데 실제로 금액에 얼마나 반영되는지 확인해 본다. 방향을 단정하지 않고 확인해 볼 값이다

X ④ (파생변수)

컬럼명	건축연차 = 계약연도 - 건축년도
의미 · 단위	지은 지 몇 해 됐는지, 년
Y와 관련 있다고 보는 이유	건축년도 원본은 Y와 상관이 0.088뿐인데, 계약 시점이 섞여 있어 값이 눌린 것으로 보인다. 연차로 바꾸면 0.147로 오르고 무엇보다 “얼마나 낡았나”라는 뜻으로 해석할 수 있게 된다

X ⑤ (파생변수)

컬럼명	계약월차 = 계약연월 - 2024년 8월
의미 · 단위	대상 기간 시작점부터 몇 번째 달인지, 개월
Y와 관련 있다고 보는 이유	24개월 동안 시장 전체가 오르내린다. 이 값을 빼놓으면 시장이 올랐던 시기에 팔린 물건의 특성을 “좋은 특성”으로 잘못 읽게 된다

X에 넣지 않기로 한 것: m 당 가격. 거래금액을 전용면적으로 나눈 값이라 Y에서 만들어진 값이다. 넣으면 예측이 거의 완벽해지지만 아무것도 예측한 것이 아니다.

가설

- ① 전용면적이 넓을수록 거래금액이 높을 것이다.
- ② 자치구와 계약월차를 맞춰 비교해도 건축연차가 긴 아파트가 짧은 아파트보다 거래금액이 낮을 것이다.
- ③ 층은 거래금액과 뚜렷한 방향을 보이지 않을 것이다. 1층을 빼면 층별 차이가 크지 않을 것으로 본다.

작성방법 설명

• 핵심 질문

- 데이터로 답이 나오는 형태로 씁니다.
- “어떻게 하면 집을 싸게 살까”(×) — 방법은 데이터에 없습니다.
- “지은 지 오래된 아파트일수록 거래금액이 낮게 나타나는가”(○)

• 문제 유형

- 근거는 Y의 척도입니다. “분류를 하고 싶어서”(×) → “Y가 금액이라 연속형”(○)
- 연속형 Y를 억지로 구간으로 잘라 분류로 바꾸면 자르는 기준을 스스로 정해야 하고 “얼마나 차이 나는가”라는 정보가 버려집니다. 굳이 그렇게 한다면 이유를 적으세요.

• 목표변수 Y

- 분포는 지금 세어 둡니다. 범주가 9:1로 쏠려 있으면 전부 다수 범주로 찍기만 해도 정확도 90%가 나옵니다. 나중에 발견하면 평가 지표부터 다시 정해야 합니다.

- 연속형이라면 최소·최대·중앙값·평균을 적고 평균과 중앙값이 크게 벌어지는지 확인합니다. 위 예시처럼 벌어지면 그대로 회귀에 넣기 어려워 로그 변환을 검토해야 합니다.

• 설명변수 X

- 컬럼명을 그대로 옮겨 적습니다. “아파트 정보들”처럼 뭉뚱그리면 다음 주에 무엇을 쓸지 다시 정해야 합니다.
- 원본 컬럼을 가공해 쓸 계획이라면 위 X ④·⑤처럼 계산식과 함께 적습니다.
- Y에서 만들어진 값을 넣으면 안 됩니다. 위 예시의 m²당 가격이 그렇습니다. 별점으로 긍정/부정 라벨을 만들어 놓고 별점을 설명변수로 넣는 것과 같은 실수이고 매년 나옵니다. 목록을 다 적은 뒤 하나씩 “이 값은 Y가 정해지기 전에 알 수 있는 값인가”를 물어보세요.
- X와 Y 양쪽에 영향을 주는 변수를 빠뜨리기 쉽습니다. 아이스크림 판매량과 익사 사고 수는 같이 올라가지만 둘 다 기온 때문입니다. 위 예시에서는 자치구와 계약 시점이 그 자리에 있어 X ②·⑤로 넣고 이유를 밝혔습니다.

• 가설

- 방향까지 적고 틀릴 수 있는 문장으로 씁니다. “넓으면 비싸다”처럼 결과가 뻔한 문장은 확인해도 얻는 게 없습니다.
- 위 가설 ②처럼 “조건을 맞춰서 비교해도 그런가”를 묻는 형태, 가설 ③처럼 “관계가 없을 것이다”라고 거는 형태가 확 인할 가치가 있습니다.

• 이 절을 다 쓴 뒤 점검

- 핵심 질문 · 문제 유형 · Y 세 가지를 나란히 놓고 읽어 봅니다. 셋이 같은 것을 가리켜야 합니다.
- 질문은 “어느 집단이 더 높은가”인데 Y는 연속값이고 문제 유형은 회귀로 적어 놓는 식의 어긋남이 매년 나옵니다. 이 상태로 5주를 가면 마지막에 질문과 결과가 맞지 않아 결론을 못 씁니다.
- 위 예시는 질문도 “얼마나 낮은가”, Y도 연속형 금액, 유형도 회귀로 맞물려 있습니다. 어긋났다면 셋 중 무엇을 고칠지 지금 정하세요. 대개 질문을 다듬는 쪽이 빠릅니다.

4. 데이터 실물 확인

행 × 열	59,842행 × 10열
결측 많은 컬럼	해제사유발생일 57,918건(96.8%). 나머지 9개 컬럼은 결측 없음
이상한 값	거래금액 최댓값 1,150,000만원(115억), 전용면적 최댓값 273.9m ² . 확인해 보니 오류가 아니라 실제 대형 평형. 총 값에 -1이 312건 있는데 지하층을 뜻함
Y 분포	9,500~1,150,000만원, 중앙값 92,000, 평균 128,340. 평균이 중앙값보다 커서 오른쪽으로 꼬리가 긴 형태
중복 행	0건. 다만 같은 단지·같은 날짜 거래가 여러 건 있는데 층이 달라 서로 다른 거래다
자료형이 잘못 읽힌 컬럼	거래금액이 82,500처럼 콤마가 들어간 문자열이라 문자로 읽힘. 건축년도와 층도 문자열
범주형 컬럼의 값 종류 수	자치구 25종 — 더미 인코딩해도 열이 24개만 늘어 부담 없음. 아파트 이름은 3,847종이라 그대로 못 씀

발견한 내용

가장 먼저 걸린 건 **결측이 결측이 아니었다**는 점이다. 해제사유발생일이 96.8% 비어 있어서 처음에는 쓸모없는 컬럼으로 보고 지우려 했다. 그런데 이 값이 채워진 1,924건은 계약이 취소된 거래였다. 컬럼을 지웠으면 실제로 성사되지 않은 거래 1,924건이 그대로 분석에 들어갈 뻔했다. 비어 있는 쪽을 남기고 채워진 쪽을 빼는 것이 맞다.

자치구가 가격의 대부분을 설명한다는 것도 분명해졌다. 강남구 중앙값 245,000과 노원구 51,500이 다섯 배 가까이 벌어져서 자치구를 넣지 않고 모델을 돌리면 다른 변수들이 자치구를 대신 설명하는 꼴이 된다. 강남구에 큰 평수가 많다면 면적의 효과가 실제보다 부풀려진다. 그래서 자치구를 X에 넣고 EDA 단계에서 구별로 나눠서도 확인하기로 했다.

거래금액이 콤마 때문에 문자로 읽히는 것도 미리 열어보지 않았으면 놓쳤을 문제다. 그대로 두면 평균조차 계산되지 않는다. 총의 -1도 처음에는 오류로 봤는데 지하층을 뜻하는 값이었다. 그냥 지우면 반지하 거래 312건이 사라진다.

아파트 이름은 3,847종이다. 그대로 더미 인코딩하면 열이 3,847개로 불어나고 한 단지에 거래가 한두 건뿐인 곳도 많아 학습이 되지 않는다. X에서 빼고 자치구 단위로만 보기로 했다.

한 가지 더, **실거래 자료에는 팔린 물건만 있다**. 내놔는데 안 팔린 물건은 기록되지 않는다. 그래서 여기서 나오는 결론은 “거래된 아파트의 가격을 가르는 요인”이지 “서울 아파트 전체의 가치”가 아니다. 발표 자료의 한계장에 적기로 했다.

아직 전처리는 하지 않았다. 위 수치는 `info() · describe() · value_counts() · isna().sum()`으로 확인만 한 결과다.

작성방법 설명

• 확인 방법 (표 전체 공통)

- 데이터를 직접 내려받아 `head() · info() · describe() · value_counts() · isna().sum()`으로 확인하고 그 결과를 옮겨 적습니다. 남의 노트북 화면을 보고 적으면 안 됩니다.
- 데이터의 모습을 확인하지 않은 채 주제를 확정하면, 분석을 시작한 뒤에 데이터 상태 때문에 주제를 바꾸거나 포기하게 됩니다.
- 아직 전처리는 하지 않습니다. 여기서는 무엇이 있는지 보기만 합니다.
- 없다는 것도 확인 결과입니다. 찾아봤는데 없었다면 위 예시처럼 그렇게 적어 두세요.

• 결측 많은 컬럼

- 결측 30%가 넘는 컬럼은 채우는 것보다 버리는 쪽이 나을 때가 많습니다.
- 다만 그 컬럼이 3절 X에 들어 있다면 계획부터 다시 봐야 합니다.
- **비어 있는 게 정상인 칸도 있습니다**. 위 예시의 해제사유발생일이 그렇습니다. 지우기 전에 그 컬럼이 무슨 뜻인지 설명 문서에서 확인하세요.

• 이상한 값

- 무응답을 9, 99, 999로 코딩해둔 데이터가 흔합니다. 숫자로 읽히니 오류처럼 안 보이지만 그대로 두면 평균이 망가집니다. 나이 999, 소득 -1도 같은 종류입니다.
- `describe()`의 최댓값이 유난히 크면 의심하세요. 다만 확인해 보고 실제 값이면 그대로 둡니다. 위 예시의 115억짜리 거래가 그런 경우입니다.
- 음수도 무조건 오류는 아닙니다. 위 예시의 총 -1은 지하층을 뜻하는 정상 값이었습니다.

• Y 분포

- 3절 목표변수 Y 칸과 같은 값을 적게 됩니다. 두 곳이 다르면 한쪽이 잘못된 것입니다.

• 중복 행

- `df.duplicated().sum()`으로 셉니다. 여러 파일을 합친 데이터에서 특히 자주 나오고 그대로 두면 같은 행이 여러 번 학습됩니다.
- 반대로 겹보기에 같아 보이는데 실제로는 다른 건도 있습니다. 위 예시의 같은 단지·같은 날짜 거래가 그렇습니다.

• 자료형이 잘못 읽힌 컬럼

- `info()`에서 숫자여야 할 컬럼이 object로 나오면 값 안에 쉼표나 단위 문자가 섞여 있을 가능성이 큼니다.
- 82,500이나 35kg 같은 값 하나 때문에 열 전체가 문자로 읽힙니다.

• 범주형 컬럼의 값 종류 수

- 위 예시의 아파트 3,847종처럼 종류가 많으면 그대로 더미 인코딩했을 때 열이 그만큼 불어납니다.
- 반대로 어떤 범주의 건수가 극단적으로 적으면, 학습·검증 분할에서 한쪽으로 몰려 그 범주의 결과가 무의미해집니다.

• 발견한 내용

- 표의 숫자만으로 설명이 안 되는 부분을 씁니다.
- 이상해 보이는 값이 실제 오류인지, 1절의 데이터 단위나 자료의 성격 때문에 나올 수 있는 값인지 구분해 보세요.
- 표본이 어느 쪽으로 기울었는지도 함께 봅니다. 위 예시의 “팔린 물건만 있다”가 그런 경우입니다. 바꿀 수 없는 편향이 라면 결론의 범위를 좁혀서 적습니다.
- 여기서 걸린 문제는 6절의 대응 계획으로 이어지게 씁니다.

5. 수행 계획

주차	할 일	그 주에 나오는 결과물
1주차	파일 600개를 하나로 합치기, 해제된 거래 1,924건 제외, 거래금액 콤마 제거 후 숫자 변환, 건축년도·층 숫자 변환, 지역코드를 구 이름으로 매핑, 파생변수 3개 생성(건축연차, 계약월차, m당 가격 — m ² 당 가격은 확인용이며 X에 넣지 않음)	전처리 노트북 1개 + apt_clean.csv
2주차	변수별 분포 확인, 거래금액 로그 변환 여부 판단, 자치구별 가격 비교(박스플롯 + 분산 분석), 자치구를 고정한 뒤 건축연차와 가격 관계 확인, 계약월차에 따른 시장 흐름 확인	EDA 노트북 1개 + 그래프 8장, 가설 ①②③에 대한 1차 판정
3주차	선형회귀·랜덤포레스트·그래디언트 부스팅 학습, RMSE·MAE·R ² 로 비교, 변수 중요도로 자치구와 건축연차의 기여도 확인	모델 3개 성능 비교표 + 변수 중요도 그래프
4주차	가설 ①②③ 최종 판정과 결과 해석 정리, 발표용 PPT 작성(주제·데이터 소개 → EDA → 모델 비교 → 결론과 한계), 2절·6절에서 적은 데이터 한계를 결론 장에 반영, 조원 리허설 1회	발표용 PPT 15장 내외 + 발표 대본
5주차	발표에서 받은 피드백을 항목별로 정리, 분석을 다시 돌려야 하는 지적부터 반영(예: 로그 변환 여부 변경), 그래프 축·설명 문구 수정, 결론 문장 다듬기, 최종본 제출	피드백 반영 목록(고침/안 고침 + 이유) + 최종 PPT + 최종 노트북

작성방법 설명

• 할 일

- 이 데이터에서 실제로 해야 하는 작업으로 씁니다. “전처리”(X) → “거래금액 콤마 제거 후 숫자 변환, 해제된 거래 1,924건 제외”(O)

- 4절에서 확인한 내용이 그대로 1주차 할 일이 됩니다. 4절과 5절이 이어지지 않으면 둘 중 하나가 부실한 것입니다.

• 그 주에 나오는 결과물

- 끝났다고 말할 수 있는 것을 하나씩 적습니다. “EDA 하기”, “전처리 하기”는 언제 끝난 건지 알 수 없어 계획 구실을 못 합니다.
- clean.csv 1개, 그래프 8장, 성능 비교표 1개처럼 파일이나 개수로 셀 수 있으면 그 주가 끝났는지 스스로 판단할 수 있습니다.

• 주차 배분

- 전처리는 생각보다 오래 걸립니다. 1주차에 전처리와 모델링을 같이 넣은 계획은 거의 밀립니다. 처음 해 보는 작업이라면 예상 시간의 두 배로 잡으세요.
- 밀릴 것을 미리 가정하고 우선순위를 정해 둡니다. “모델 3개 중 2개를 먼저 돌리고 나머지는 시간이 남으면”처럼 적어 두면, 마지막 주에 무엇을 포기할지 고민하지 않아도 됩니다.
- 5주로 부족하면 주차를 더 늘려 잡아도 됩니다. 무리한 계획을 적어 내는 것보다 낫습니다.

• 발표 PPT 주차

- 한 주를 따로 잡으세요. 분석이 끝나면 발표 자료는 금방 만들 수 있다고 생각하지만 그렇지 않습니다. 그래프를 발표용으로 다시 그리고 축 이름과 단위를 붙이고 순서를 짜고 말로 설명해 보는 데 시간이 걸립니다. 모델링 주차에 끼워 넣으면 결국 발표 전날 밤에 몰립니다.
- 구성은 이 보고서의 순서를 그대로 따라가면 됩니다. 주제와 데이터 소개(1·2절) → 분석 설계와 가설(3절) → 데이터 확인과 EDA(4절) → 모델 결과 → 결론.
- 마지막에 한계를 밝히는 장을 반드시 넣으세요. 6절에 적어 둔 내용이 그 장의 재료가 됩니다. 한계를 감춘 발표보다 알고 있다고 말하는 발표가 좋은 평가를 받습니다.

• 피드백 반영 주차

- 마지막 주는 새 분석을 시작하는 주가 아니라 받은 지적을 반영하는 주입니다. 여기에 모델을 하나 더 넣으면 정작 고칠 시간이 없어집니다.
- 피드백을 받으면 먼저 항목별로 적어 놓고 각각을 “고침 / 안 고침 + 이유”로 나누세요. 전부 고칠 필요는 없지만 판단한 흔적은 남겨야 합니다.
- 분석을 다시 돌려야 하는 지적(전처리 방식·변수 선택·모델 설정)과 자료만 고치면 되는 지적(그래프 축·설명 문구·발표 순서)을 나눠 두면 시간 배분이 됩니다. 다시 돌리는 쪽부터 시작하세요.
- 고치다 보면 앞 절의 내용도 같이 바뀝니다. 전처리 방식을 바꿨다면 4절 수치와 6절 대응 계획도 함께 손봐야 앞뒤가 맞습니다.

6. 예상되는 어려움

- **자치구가 다른 변수의 효과를 전부 흡수할 수 있다.** 가격의 대부분을 입지가 설명해서 정작 알고 싶은 건축 연차나 층의 기여도가 안 보일 수 있다 → 자치구를 뺀 모델과 넣은 모델을 둘 다 만들어 계수 변화를 같이 신는다. 계수가 크게 흔들리면 그 자체를 “입지 효과와 건물 특성이 분리되지 않는다”는 결과로 보고한다.
- **거래가 적은 구는 표본이 부족하다.** 종로구는 24개월치를 모아도 612건이라 구별로 나눠 보면 결과가 들쭉날쭉할 수 있다 → 구별 건수를 먼저 세고 500건에 못 미치는 구는 인접 구와 묶거나 분석에서 빼고 뺐다는 사실을 결론에 밝힌다.

- **건축연차와 재건축 기대가 뒤섞인다.** 오래된 단지가 재건축 기대로 오히려 비싸면 가설 ②는 뒤집힌다 → 뒤집히면 그것 자체를 결과로 보고한다. 연차를 구간으로 나눠 30년 넘은 단지를 따로 보고 결론에 “재건축 기대는 이 데이터로 구분할 수 없다”는 한계를 적는다.

작성방법 설명

• 걱정되는 것

- 4절에서 확인한 사실에서 끌어옵니다. “시간이 부족할 것 같다”, “어려울 것 같다”는 이 데이터에 대해 아무것도 말하지 않습니다.
- 위 예시는 셋 다 4절에서 실제로 본 것(구별 중앙값 차이, 종로구 612건, 건축연차의 두 방향)에서 나왔습니다. 4절을 제대로 봤다면 걱정거리는 저절로 나옵니다.

• 대응

- 걱정과 화살표로 짝지어 적습니다. 플랜 B는 미리 정해둘 때만 플랜입니다. 닥쳐서 정하면 그냥 사고입니다.
- 실행 가능한 조치여야 합니다. “열심히 한다”, “다른 방법을 찾아본다”(×) → “자치구를 뺀 모델과 넣은 모델의 계수 변화를 같이 심는다”(○). 조원이 그 문장만 읽고 바로 움직일 수 있으면 충분합니다.
- 문제를 완전히 없애지 못하는 경우도 많습니다. 그럴 때는 한계를 결론에 밝히는 것도 대응입니다. 위 첫 번째 항목의 “분리되지 않는다는 것 자체를 결과로 보고”, 세 번째 항목의 “이 데이터로 구분할 수 없다고 적는다”가 그런 방식입니다.

• 개수

- 두세 개면 충분합니다. 걱정을 많이 적는 것보다 실제로 벌어질 법한 것을 골라 대응을 구체적으로 쓰는 편이 낫습니다.