

머신러닝 캡스톤 평가 피드백

항목	내용
이름	이새찬
제출 형태	노트북 4개 분할(EDA / 모델 선정 / XGB 변수 중요도 / SHAP)
최종 점수	53 / 100 (미션 점수 51 + 가산점 2)

1. 총평

- 판단 근거를 데이터에서 끌어내는 감각이 좋습니다. 미션 4에서 bedrooms·bathrooms의 25%·50% 값이 모두 1이라는 관찰에서 “1 이상인지 미만인지로 거주공간 특성이 바뀐다”는 파생변수 아이디어를 도출하셨습니다. 미션 3에서 “Manhattanville은 1개, Soho는 58개로 표본 차이가 7,072달러의 차이를 만들어 유의해졌을 가능성”을 의심하신 것도 통계 결과를 그대로 믿지 않은 태도입니다.
- 미션 6의 군집 수 결정이 이 반에서 가장 촘촘합니다. k=2부터 6까지 이너서·실루엣·두께비·최소상대면적·균형지수를 하나씩 비교하고 근거를 문단으로 정리하셨습니다.
- building_era 기준 근거도 최우수입니다. 데이터셋 README로 기준연도가 2016년임을 확인하고 준공 연도를 복원한 뒤 뉴욕 Pre-war(1900~1939)와 1974년 임대료 안정화제도 경계로 4단계를 만드셨습니다. 쓸 수 없는 정보(세대 수·실제 규제 여부)까지 한계로 명시하셨습니다.
- 미션 8부터 해석이 사라집니다. 베이스라인 11종, 튜닝 11종, 과적합 진단 3종, 변수 중요도, SHAP 요약표까지 실행은 다 하셨는데 그 출력으로 무엇을 판단했는지 적은 문단이 없습니다. 마지막 셀은 KeyError로 끝나 Dependence Plot이 나오지 않았고 Waterfall과 다섯 줄 결론도 없습니다.
- 분석 실력과 점수 사이의 격차가 이 반에서 가장 큼니다. 앞 단원의 판단력이면 미션 8~13도 충분히 쓰실 수 있었습니다.

2. 미션별 점수

미션	배점	득점	감점 사유
1. 표본 구조·품질 점검	5	4	최댓값 현실성 판단 미완
2. 기술통계·분포 판정	5	5	—
3. 이변량 분석	7	4	2집단 검정 결과 미정리 / 비유의 변수 미발견
4. 다변량 중복 점검	6	6	—
5. 연속형 파생변수 설계	9	4	연속형 파생 4종 미달 / 처리 기준·정의표 없음
6. 고차원 명목형 재설계	10	7	병합 결과를 군집에 반영하지 않음
7. 투입 변수 확정	10	6	사유표 없음 / 상관 0.95 중복 투입

미션	배점	득점	감점 사유
8. 베이스라인 구축·모델 비교	9	5	해석 전무 / 후보 선정 근거 없음
9. 하이퍼파라미터 튜닝	8	2	전후 비교 없음 / 판단 없음
10. 과적합 진단	9	2	판단·탈락 사유 전무
11. 변수 중요도·축소	8	3	탈락 변수 미해석 / 전후 비교 없음
12. SHAP 영향력 해석	7	2	해석 전무
13. 시각화·다섯 줄 결론	7	1	Dependence 오류 / Waterfall·결론 없음
소계	100	51	
가산점	+5	+2	
합계		53	

3. 감점 상세

미션 1 — 최댓값 현실성 판단 미완 (-1)

- 중복 27건 제거, 결측 0건, 0값 4종의 의미 해석, borough를 “단일값이므로 분산 0”으로 판정하신 것 모두 정확합니다.
- “준공 후 경과 연수 최대값 180년. 확인 필요” 로 끝났습니다. 확인이 필요하다고 적으신 뒤 확인하지 않으셨습니다.
- “확인이 필요하다”는 관찰이고 “가능하다/불가능하다”가 판정입니다. 채점은 판정을 봅니다.
- 180년은 가능한 값입니다. 기준년도가 2016년이므로 준공연도는 1836년이고 맨해튼에는 19세기 건물이 남아 있습니다. 흥미로운 점은 **미션 6에서 이미 기준년도 2016년을 찾아내셨다는 것입니다.** 그 정보로 미션 1의 “확인 필요”를 채우셨다면 두 미션이 연결됐습니다.

미션 3 — 2집단 검정 결과 미정리, 비유의 변수 미발견 (-3)

- 상관분석은 잘하셨습니다. 검정 방법·상관계수·부호·크기·유의성을 표에 채우고 “종속변수 rent가 정규성을 만족하지 못했기 때문에 모두 Spearman을 사용”이라는 근거도 밝히셨습니다.
- 3집단 분산분석도 좋습니다. 효과크기 Medium을 읽고 표본 불균형이 유의성을 만들었을 가능성까지 지적하셨습니다.
- 2집단 명목형 8종의 검정 결과를 정리한 표나 해석이 없습니다. 반복문으로 8종을 전부 검정해 출력까지 뽑으셨는데, 마크다운은 “1. 연속형 독립변수” 다음이 바로 “3. 3집단 이상 명목형”입니다. 2번 항목이 비었습니다.

- 그래서 미션 3이 가장 중요하게 본 항목이 미답이 됐습니다. “월세에 아무런 차이를 만들지 못하는 편의시설이 무엇인지 찾아낸 뒤 그 변수를 어떻게 처리할지 결론을 내린다.” 감점 기준표에도 “비유의 변수 미발견 (-3)”이 있습니다.
- 출력에 답이 있었습니다. no_fee는 양측 p=0.595로 8종 중 유의확률이 가장 높고, 오히려 수수료 없는 매물의 평균 월세가 더 낮습니다(4,754달러 대 5,407달러).
- “배송비 무료” 스티커가 붙은 상품이 오히려 안 팔리는 재고인 경우와 비슷합니다. 수수료 면제는 프리미엄이 아니라 잘 안 나가는 매물의 유인책으로 보입니다. 이런 변수를 찾아내는 것이 미션 3의 목적이었습니다.
- 미션 7 투입 변수에서 no_fee를 빼셨으니 판단은 하셨는데 근거가 기록되지 않았습니다.

미션 5 — 연속형 파생 4종 미달 (-3)

- 만드신 것은 relative_size, relative_floor, amenity_count 세 개입니다. 미션 5는 “연속형 파생변수를 4종 이상 만든다”를 요구했습니다.
- 지시서가 제시한 네 관점 중 “방 하나를 얼마나 넓게 쓰나 — 전용 면적 ÷ (침실 수 + 욕실 수)”가 빠졌습니다. 관점 표에는 이 항목 대신 “원룸·공용화장실 (0,1)”을 넣으셨는데 이건 범주형이라 연속형 개수에 들어가지 않습니다.
- 빠진 변수가 이 미션의 핵심 학습 지점이었습니다. 출제 의도는 “나룻섬 하나가 만들어 내는 무한대를 직접 겪고 처리 기준을 말로 남겨 보게” 하는 것입니다.
- size_sqft ÷ (bedrooms + bathrooms)에서 분모가 0인 매물이 2건 있습니다. 침실도 없고 전용 욕실도 없는 매물인데, 미션 1에서 기록하신 두 개의 0이 겹친 결과입니다. 피자 한 판을 0명이 나눠 먹으면 한 명당 몇 조각인가에는 답이 없고, 컴퓨터는 이런 계산을 무한대(inf)로 적습니다.
- 제출물의 무한대 점검 결과는 “0건”입니다. 점검 코드는 정확한데 점검 대상에 분모가 0이 될 수 있는 변수가 없었습니다. 절차는 배우셨는데 그 절차가 필요한 상황을 만들지 않으셨습니다.

미션 5 — 처리 기준·정의표 없음 (-2)

- 무한대가 0건이었으니 처리할 것이 없었던 것은 맞습니다. 산출물에는 “무한대 발생 건수와 비율, 처리 기준과 처리 후 데이터 크기”가 명시되어 있고 지시서에 5% 기준까지 제시되어 있었습니다. 발생하지 않았다면 “5% 기준을 적용할 상황이 없었다”는 한 줄이라도 남기셔야 기준을 알고 있음이 드러납니다.
- 파생변수 정의표(이름·계산식·의미)도 없습니다. 도입부에 관점 표는 있지만 실제로 만드신 변수의 이름·계산식·의미를 정리한 표가 없어 코드를 읽어야 알 수 있습니다.
- 2차 파생변수 점검 셀 세 개가 전부 주석 처리되어 있습니다. relative_amenity_ratio를 만들려다 분자·분모가 모두 0인 경우를 처리하며 포기한 흔적으로 보입니다. 그 과정 자체가 미션 5가 원하는 경험이니 무엇을 시도했고 왜 접었는지 한 줄 적으시면 그것이 산출물이 됩니다.
- 2차 파생으로 제출하신 amenity_level은 amenity_count를 구간화한 것입니다. 1차를 재료로 쓰셨으니 순서는 맞습니다. 다만 나룻섬이 아니라 구간화라서 “오염된 값으로 만든 파생은 오염을 물려받는다”는 교훈이 드러나지 않습니다.

미션 6 — 병합 결과를 군집에 반영하지 않음 (-3)

- neighborhood_grp를 만들어 1% 미만 동네를 OTHER로 묶는 코드는 정확합니다.
- 군집 프로파일을 만들 때 .groupby("neighborhood", observed=True)로 **병합 전 원본 컬럼**을 쓰셨습니다. 그 결과 32개 동네가 그대로 들어갔고 군집 결과에 Manhattanville(1건), West Harlem(2건), Little Italy(3건)가 남아 있습니다.
- 미션 6은 두 단계를 순서대로 밟으라고 했습니다. “① **희소 수준 병합** → ② **동네를 성격별로 묶기(군집)**”입니다. 병합을 먼저 하는 이유는 명확합니다. 매물 1건으로 계산한 “동네 평균 면적”은 그 매물 한 채의 면적일 뿐이고 동네를 대표하지 못합니다.
- 반 평균 점수를 낼 때 한 명만 있는 반의 평균은 그 한 명의 점수입니다. 그 값을 서른 명짜리 반의 평균과 나란히 놓고 군집을 만들면 표본이 적은 반이 극단값으로 튀어 경계를 혼듭니다.
- 실제로 군집 프로파일 범위가 mean_size 433~1,397, mean_building_age 4~111로 나오는데, 병합 후 21개로 계산하면 768~1,397, 20~85로 좁아집니다. 희소 동네가 양쪽 끝을 만들고 있었습니다.
- 고치는 방법은 한 글자입니다. groupby("neighborhood")를 groupby("neighborhood_grp")로 바꾸시면 됩니다. 만드신 변수를 쓰지 않은 것이 감점 원인이지 절차를 몰라서가 아닙니다. 병합 코드와 k 결정 근거는 이 반에서 가장 잘 쓰셨습니다.

미션 7 — 채택·제외 사유표 없음 (-3)

- 파생변수 검증은 전수로 하셨습니다. 연속형 상관, 2집단 검정, 3집단 ANOVA와 사후검정, 파생변수끼리 상관행렬까지 빠뜨린 것이 없습니다.
- 채택·제외 사유표가 없습니다. 투입 변수를 정한 셀에 코드 주석 두 줄이 있는데 내용이 이렇습니다.

```
# -> condition_grp      : 병합 후에도 비유의( $p=0.490$ ) → 보류가 아니라 제외로 결론  
# -> density_vs_neighbor : 상관 최약(+0.172)에 왜도 최약(+21.9) → 제외
```

- **이 두 변수는 이 노트북에 존재하지 않습니다.** 다른 과제에서 셀을 가져와 편집하다 남은 주석입니다. 그래서 실제 투입 변수 8종에 대한 사유는 한 줄도 없습니다.
- 미션 7은 “변수마다 채택 또는 제외의 사유를 한 줄씩 붙인다”고 요구했고, 출제 의도에 “여기서 확정된 변수 목록이 8번부터 14번 미션까지의 유일한 입력이므로 이 미션이 프로젝트 전체의 허리”라고 적었습니다. 배점 10점 중 3점이 사유표에 걸려 있습니다.
- 이삿짐을 다 싸 놓고 상자에 무엇이 들었는지 적지 않은 상태입니다. 짐은 제대로 싸였는데 나중에 열어 볼 사람이 하나씩 뜯어봐야 합니다.
- 자료는 다 있었습니다. 미션 3·7의 검정 결과가 변수마다 나와 있으니 표 하나로 옮기시면 끝납니다. 주석이 아니라 마크다운 표로 남기셔야 산출물이 됩니다.

미션 7 — 상관 0.95 중복 투입 (-1)

- 파생변수끼리 상관행렬에서 `relative_size` `size_sqft = 0.953` 이 출력에 정확히 찍혔습니다.
- 최종 투입에 두 변수가 모두 들어갔고 중복에 대한 언급이 없습니다.
- 키를 cm로도 적고 “동네 평균 대비 몇 배”로도 적은 두 열과 같습니다. 다 넣어도 새 정보는 안 늘고 모델은 “크기 효과”를 어떻게 나눌지 헷갈립니다.
- 트리 계열은 예측이 망가지지 않지만 중요도가 쪼개져 해석이 어려워집니다. 미션 11의 중요도표에서 `size_sqft`가 0.383으로 1위인데 `relative_size`는 목록에 없습니다. VIF 제거로 빠진 것이고 그 사실이 기록되지 않았습니다.
- 미션 4에서 세우신 “가장 효과크기가 컸던 `size_sqft`를 사용해야 한다”는 결론을 여기서 적용하시면 됩니다.

미션 8 — 해석 전무, 후보 선정 근거 없음 (-4)

- `reg_baseline`으로 11종을 학습하고 순위표를 출력하셨습니다. 다음 셀이 바로 “튜닝 저장폴더 구성”입니다. 해석 마크다운이 한 줄도 없습니다.
- 미션 8이 물은 네 가지가 전부 미답입니다. 선형 계열보다 못한 모델은 몇 개인가, 가지치기 없는 트리 한 그루의 성능은 어떤가, 숲은 얼마나 나아졌는가, 상위 그룹은 몇 개인가.
- 기준선(baseline)은 “이보다 못하면 쓸 이유가 없는 선”입니다. 선을 긋는 작업이 목적이므로 선형 계열 점수를 먼저 재고 복잡한 모델이 그 선을 얼마나 넘는지 말해야 기준선이 됩니다.
- 출력에 답이 다 있었습니다. CatBoost 0.200 / XGB 0.206 / LGBM 0.206이 Contender고, RandomForest 0.213 / SVR 0.220 / Ridge·Linear 0.230이 그 아래입니다. 표를 세 문단으로 푸는 데 10분이면 4점을 지킬 수 있었습니다.

미션 9 — 튜닝 전후 비교·판단 없음 (-6)

- 11종 전체를 `practice=False`로 교차검증 기반 탐색하셨습니다. 실행은 완전하고 모델별 최적 조합·CV RMSE가 출력에 남았습니다.
- 미션 9가 요구한 것이 전부 미답입니다.
 - “검증 데이터는 탐색에 쓰지 않는다. 왜 그런지 설명하자” — 설명 없음
 - “미션 8의 표와 나란히 놓고 비교한다” — 비교표 없음
 - “가장 크게 좋아진 모델은 무엇이며, 왜 그렇게 좋아졌는가” — 답 없음
 - “미션 8에서 무너졌던 모델은 회복되었는가. 무엇이 문제였는가” — 답 없음
 - “튜닝을 더 밀어붙일 것인가, 여기서 접을 것인가?” — 판단 없음
- 시험을 다 치르고 답안지를 제출했는데 채점표를 보지 않은 상태입니다. 계산은 다 하셨으니 결과를 읽기만 하면 됩니다.

- 회복 관찰이 이 단원의 핵심입니다. Lasso·ElasticNet이 베이스라인에서 $R^2=-0.001$ 로 무너졌는데 튜닝 후 회복됐습니다. 튜닝 로그를 보면 규제 강도가 $\alpha=1.0$ 에서 **0.0001**로 내려갔습니다. 브레이크가 너무 세서 계수를 전부 0으로 눌러 놓고 있었던 것입니다. “성능이 무너졌다고 모델을 탓하기 전에 설정을 의심해야 한다”는 결론이 여기서 나옵니다.

미션 10 — 판단·탈락 사유 전무 (-7)

- 튜닝 후 상위 3종(CatBoost·XGB·LGBM)을 진단하셨습니다. 출력에 Train/CV/Test와 Gap%가 다 있고 CatBoost는 RMSE Gap 26.11%로 과대적합 판정입니다.
- 그 출력 다음 셀이 없습니다. 노트북 02가 진단 출력에서 끝납니다. 해석·탈락 모델 지목·최종 모델 선정 근거가 전부 없습니다.
- 노트북 03에서 아무 설명 없이 xgb_tuned를 로드해 변수 중요도로 넘어가셨습니다. 최종 모델을 XGBoost로 고르신 이유가 어디에도 없습니다.
- 미션 10의 출제 의도는 “검증 점수가 제일 높은 모델을 쓴다는 습관을 깨는 것”입니다. 진단 표를 만드는 것은 준비이고 그 표로 탈락과 채택을 가르는 것이 이 미션입니다. 배점 9점 중 7점이 “탈락 사유”와 “다기준 선정”에 걸려 있습니다.
- 훈련 점수는 연습문제, CV 점수는 모의고사입니다. 연습문제 0.150에 모의고사 0.203이면 이해한 게 아니라 외운 쪽입니다. 이 격차를 보고 “배포할 수 없다” 또는 “격차가 남지만 이런 이유로 쓴다”를 말하는 것이 진단의 목적입니다.
- 세 모델을 진단해 두셨으니 한 표로 모으고 “누가 탈락, 왜 탈락, 그래서 누구”를 세 문장 쓰시면 대부분 회복됩니다. 성능만이 아니라 학습 시간(출력에 있습니다)과 해석 가능성도 올리셔야 합니다.

미션 11 — 탈락 변수 미해석, 전후 비교 없음 (-5)

- 누적 95%로 6개를 채택하고 재학습·재튜닝·과적합 재진단(22.87%)까지 절차를 정확히 밟으셨습니다. 실행은 완전합니다.
- 마크다운 셀은 “7. XGBRegressor 모델에 대한 Feature Importance” 같은 절차 제목뿐이고 해석이 없습니다.
- 미션 11이 묻은 것이 전부 미답입니다.
 - “가장 큰 몫을 혼자 만드는 변수는 무엇인가” — size_sqft(38.3%)
 - “빠진 변수가 왜 빠졌는지 설명한다” — min_to_subway(2.4%)가 탈락했는데 이유 없음
 - “공들여 만든 파생변수가 빠졌다면 헛수고였는지, 다른 의미가 있었는지” — 답 없음
 - “성능은 얼마나 떨어졌는가, 과적합은 어떻게 바뀌었는가, 줄인 대가로 무엇을 얻었는가” — 전후 비교표 없음
 - “최종 배포 후보를 변수 개수까지 포함해 한 문장으로 확정하자” — 확정 문장 없음

- 반 학생 대부분이 안경을 썼다면 안경 착용 여부로는 학생을 구분할 수 없습니다. `min_to_subway`가 낮게 나온 이유도 비슷합니다. 이 데이터의 70% 이상이 역에서 5분 이내이고 `cluster_name`이 이미 위치 정보를 먼저 가져갔습니다.
- 출력에 필요한 수치가 다 있었습니다. 축소 전 Test RMSE 0.195, 축소 후 0.203, Gap 22.87%. 표 하나와 문장 네 개면 5점을 지킬 수 있었습니다.

미션 12 — 해석 전무 (-5)

- 절차 자체는 이 반에서 가장 성실합니다. `shap_analysis` 한 줄로 끝내지 않고 `TreeExplainer`를 직접 만들고 전처리를 재현한 뒤 **가산성을 거꾸로 이용해 단위를 검증**하셨습니다. `shap_2d.sum(axis=1) + base_value`가 `model.predict`와 오차 $5.9e-06$ 으로 일치함을 확인하고 “SHAP 값의 단위: 예측값(y 단위)”이라고 판정하셨습니다. 라이브러리를 블랙박스라 쓰지 않는 태도입니다.
- 요약표도 직접 조립하셨습니다. `mean_abs_shap`, `ratio`, `cum_ratio`, `mean_shap`, `std_shap`, `direction`, `cv`, `stability` 여덟 열을 다 만드셨습니다.
- 그 표를 읽은 문장이 없습니다. 마크다운은 “5. 변수별 통계량 계산”, “7. 비율과 누적 비율” 같은 절차 설명 뿐입니다.
- 미션 12가 묻은 네 가지가 전부 미답입니다.
 - “영향력 상위 두 변수가 전체의 몇 %를 차지하는가” — `size_sqft` 63.3% + `relative_floor` 12.3% = **75.6%**
 - “밀어 올리는 변수와 끌어내리는 변수는 각각 무엇인가”
 - “가장 심하게 출렁이는 변수는 무엇인가” — `std_shap`으로는 `size_sqft`(0.412)
 - “영향력은 큰데 평균 기여가 거의 0인 변수가 있는가” — 표를 보면 15개 전부 절댓값 0.004 이하입니다
- 시소는 양쪽이 번갈아 오르내려 평균 높이가 0이지만 크게 움직입니다. 평균 0은 효과가 없다는 뜻이 아니라 상쇄됐다는 뜻입니다. 이것이 미션 12의 핵심 학습 지점이었고 표에 이미 드러나 있었습니다.
- 원-핫 인코딩으로 범주형이 `building_era_0~_3`처럼 쪼개져 15개 열이 됐습니다. 이 상태로는 “건축시대가 월세를 어느 쪽으로 미는가”를 변수 단위로 읽을 수 없습니다.
`my_diag.aggregate_shap_by_category`로 묶으시면 원래 변수 단위로 되돌아옵니다.

미션 13 — Dependence 오류, Waterfall·결론 없음 (-6)

- Bar Plot과 Beeswarm Plot은 출력됐습니다. Bar Plot을 직접 그리면서 막대마다 누적 비율을 적어 넣으신 것이 좋습니다.
- Dependence Plot 셀이 **ERROR: KeyError: 'cluster_name_2'**로 끝났고 이 셀이 노트북의 마지막입니다. 그래서 다음에 있어야 할 Waterfall Plot과 다섯 줄 결론이 없습니다.
- 오류 원인은 이렇습니다. `approximate_interactions`로 상호작용 짝을 찾을 때 `x_df`(원-핫 전개된 15열)를 넘기셨는데 `dependence_plot`에 주신 `interaction_index=partner`가 'cluster_name_2'였습니다.

이 이름이 함수가 찾는 인덱스 체계와 맞지 않아 실패했습니다. 열 이름 대신 **정수 인덱스**를 넘기시거나 `my_diag.shap_dependence_plot(summary, ...)`을 쓰시면 이 문제가 없습니다.

- 미션 13이 구체적으로 물은 네 가지도 미답입니다. Beeswarm에서 색으로 방향을 읽을 수 없는 변수, Dependence로 열었을 때 보이는 것, 월세를 가장 세게 끌어내리는 권역, Waterfall 세 건의 차이입니다.
- **다섯 줄 결론이 없습니다.** 배점 7점 중 4점이 결론과 사용 범위에 걸려 있습니다. 13개 미션은 이 다섯 줄을 쓰기 위한 준비였습니다. 특히 5번 “믿을 수 있는 범위”는 “반드시 쓴다”고 명시된 항목이고, 재료는 미션 1에서 확보해 두셨습니다. borough가 전 행 Manhattan이라는 사실, 면적 250~4,800 sqft, 월세 1,300~20,000달러 범위로 “맨해튼 한 자치구, 특정 시점 스냅샷으로 학습했으므로 브루클린·퀸스나 다른 시점에는 쓸 수 없다”는 문장이 바로 나옵니다.
- 오류가 난 셀에서 작업을 멈추지 않는 것이 중요합니다. Dependence Plot이 실패했더라도 Waterfall과 결론은 독립적으로 쓸 수 있었습니다. 한 셀이 막혔을 때 우회하거나 그 항목만 비우고 나머지를 채우시면 6점 중 상당 부분을 지킬 수 있습니다.

4. 가산점

항목	배점	인정	근거
제시 외 파생변수 직접 설계·검증	+2	+2	bed_bath_constraint(기술통계 관찰에서 도출), building_era(데이터셋 README로 기준년도 확인 + NYC Pre-war·1974 임대료 안정화제도 근거로 4단계), amenity_level — 검정까지 수행
예측값을 USD로 되돌려 잔차 해석	+2	0	로그 단위로만 보고
데이터 누수 위험 자체 발견·기록	+1	0	군집에서 rent 제외는 지시서 지침 이행